

Оптимизация гиперпараметров гибридной рекомендательной системы с использованием алгоритмов многоруких бандитов

Выполнил: Шитоев Данил

16 июня 2026 г.

Содержание

1	Введение и постановка задачи	2
2	Теоретические основы многоруких бандитов	2
3	Архитектура рекомендательной системы	2
4	Методология эксперимента	3
4.1	Данные и предобработка	3
4.2	Протокол оценки	3
5	Результаты и анализ	3
5.1	Анализ поведения алгоритмов	3
5.2	Оценка по гиперпараметрам	4
6	Выводы	4

1 Введение и постановка задачи

Современные рекомендательные системы (РС) сталкиваются с проблемой выбора оптимальных гиперпараметров, которые напрямую влияют на качество выдачи. Традиционные методы, такие как Grid Search или Random Search, требуют значительных вычислительных ресурсов и не адаптируются к изменениям в поведении пользователей (concept drift). В промышленной практике для решения данной задачи успешно применяются алгоритмы многоруких бандитов, позволяющие в режиме реального времени балансировать между *исследованием* (exploration) новых конфигураций и *использованием* (exploitation) уже проверенных оптимальных решений.

Цель работы: Реализовать и сравнить три классических алгоритма МАВ для автоматического подбора гиперпараметров гибридной РС, оценить их эффективность по метрикам качества ранжирования и сформулировать рекомендации по внедрению.

2 Теоретические основы многоруких бандитов

Задача многорукого бандита формализуется как последовательное принятие решений в условиях стохастической среды. На каждом шаге t алгоритм выбирает действие (руку) $a_t \in \{1, \dots, K\}$ и получает награду $r_t \in \{0, 1\}$. Цель — максимизировать суммарную ожидаемую награду за горизонт T , или минимизировать сожаление (regret):

$$R(T) = \sum_{t=1}^T (\mu^* - \mu_{a_t}), \quad (1)$$

где μ^* — математическое ожидание награды лучшей руки, μ_{a_t} — ожидание выбранной руки.

В работе реализованы три алгоритма:

1. **Epsilon-Greedy (ϵ -Greedy):** С вероятностью ϵ выбирается случайная рука (exploration), с вероятностью $1 - \epsilon$ — рука с максимальным эмпирическим средним (exploitation). Обновление среднего значения производится инкрементально: $Q_n = Q_{n-1} + \frac{1}{n}(r - Q_{n-1})$.
2. **Upper Confidence Bound (UCB1):** Алгоритм использует принцип «оптимизма в условиях неопределенности». Выбирается рука, максимизирующая верхнюю границу доверительного интервала:

$$UCB_i(t) = \hat{\mu}_i + c \sqrt{\frac{\ln t}{n_i}}, \quad (2)$$

где c — параметр исследования, t — общее число шагов, n_i — число выборов руки i .

3. **Thompson Sampling (TS):** Байесовский вероятностный алгоритм. Для каждой руки поддерживается апостериорное распределение вероятности успеха. Для бинарных наград используется бета-распределение $Beta(\alpha, \beta)$. На каждом шаге генерируется выборка $\theta_i \sim Beta(\alpha_i, \beta_i)$ для всех рук, и выбирается рука с максимальным θ_i . Параметры обновляются по правилу: $\alpha \leftarrow \alpha + 1$ при успехе, $\beta \leftarrow \beta + 1$ при неудаче.

3 Архитектура рекомендательной системы

В качестве базовой модели использована каскадная гибридная архитектура, состоящая из двух этапов:

- **Retrieval (Content-Based):** Векторизация названий и описаний игр с помощью TF-IDF. Формирование профиля пользователя как среднего вектора лайкнутых игр. Выбор топ- N кандидатов по косинусному сходству. Параметр `pool_size` $\in \{50, 100, 150\}$.
- **Ranking (Hybrid KNN + CB Blend):** Ранжирование кандидатов с использованием коллаборативной фильтрации (User-Based + Item-Based KNN) и смешивания с контентными скорями. Параметр `cb_weight` $\in \{0.1, \dots, 0.6\}$ определяет долю влияния текста в финальном скоринге. Дополнительно применяется популяционный буст $(+0.05 \cdot \text{norm_pop})$.

Пространство действий бандита состоит из $K = 3 \times 6 = 18$ уникальных конфигураций гиперпараметров. Наградой выступает бинарный сигнал *Hit@10*: $r = 1$, если тестовая игра пользователя попала в топ-10 рекомендаций, иначе $r = 0$.

4 Методология эксперимента

4.1 Данные и предобработка

Использован датасет `steam_reco_with_descriptions.csv`, содержащий взаимодействия пользователей, тексты отзывов, жанры и описания игр. Отфильтрованы только положительные отзывы ($y_recommended = 1$). Текст очищен от пунктуации, названия игр дублированы трижды для усиления весов TF-IDF. Построена разреженная бинарная матрица взаимодействий $R \in \mathbb{R}^{3951 \times 351}$.

4.2 Протокол оценки

Применена стратегия разбиения *Leave-One-Out*: для каждого пользователя одна игра случайным образом выделяется в тест, остальные формируют тренировочную историю. Симуляция проводилась оффлайн: алгоритм последовательно обрабатывал пользователей, выбирал конфигурацию, генерировал рекомендации, получал награду и обновлял внутренние параметры. Эксперимент повторялся для всех трех алгоритмов при фиксированном seed (42).

5 Результаты и анализ

Итоговые метрики, полученные в ходе симуляции, представлены в таблице 1.

Таблица 1: Сравнительные результаты алгоритмов MAB

Алгоритм	Avg HitRate@10	Лучшая конф.	Best CTR	Показы лучшей	Время, сек
Epsilon-Greedy ($\epsilon = 0.1$)	0.1362	Pool=150, Weight=0.1	0.1609	746	5.28
UCB1 ($c = 2$)	0.1357	Pool=100, Weight=0.5	0.1752	274	5.68
Thompson Sampling	0.1379	Pool=100, Weight=0.1	0.1599	442	5.70

5.1 Анализ поведения алгоритмов

- **Thompson Sampling** показал наилучший средний HitRate (0.1379). Алгоритм быстро сконцентрировал трафик на конфигурациях с низким весом СВ (0.1) и средним пулом (100), при этом сохраняя умеренное исследование альтернатив. Вероятностный механизм выборки обеспечил естественный баланс exploration/exploitation без явных гиперпараметров.

- **UCB1** продемонстрировал наивысший пиковый CTR лучшей руки (0.1752), но более низкий средний показатель. Это обусловлено агрессивным исследованием: логарифмический бонус заставлял алгоритм проверять редко выбираемые конфигурации даже после выявления лидера, что снизило среднюю эффективность на коротком горизонте ($T \approx 3951$).
- **Epsilon-Greedy** занял промежуточное положение. Фиксированная вероятность случайного выбора (10%) привела к стабильному, но неоптимальному распределению трафика. Алгоритм не адаптирует интенсивность исследования со временем, что в долгосрочной перспективе менее эффективно, чем TS или UCB.

5.2 Оценка по гиперпараметрам

Все три алгоритма согласились в том, что низкий вес контентной части (`cb_weight = 0.1–0.3`) на этапе ранжирования работает лучше высоких значений. Это указывает на то, что статистика коллаборативной фильтрации (KNN) является более надежным предиктором, чем текстовое сходство. Контентная модель эффективно выполняет роль фильтра на этапе Retrieval, и дублирование ее влияния на этапе Ranking избыточно. Размер пула 100–150 подтверждает необходимость широкого охвата для снижения риска отсека релевантных игр.

6 Выводы

1. **Эффективность TS:** Алгоритм Thompson Sampling является оптимальным выбором для динамической оптимизации гиперпараметров рекомендательных систем в условиях бинарных наград и ограниченного горизонта. Он обеспечивает максимальный средний HitRate при минимальных вычислительных накладных расходах.

2. **Целеполагание и выбор алгоритма:** Если приоритетом является максимизация краткосрочной прибыли (среднего CTR), рекомендуется Thompson Sampling. Если цель — поиск абсолютного потолка качества конкретной конфигурации для последующей фиксации, предпочтительнее UCB1 благодаря гарантированному покрытию пространства параметров.

3. **Архитектурные выводы:** Каскадная гибридная модель (CB Retrieval + KNN Ranking) демонстрирует высокую устойчивость. Бандиты подтвердили, что доминирование коллаборативной фильтрации на этапе ранжирования совместно с широким контентным пулом кандидатов дает наилучшие результаты.

4. **Практическая значимость:** Внедрение МАВ позволяет РС адаптироваться к дрейфу пользовательских предпочтений без ручного переобучения. Система автоматически перераспределяет трафик между стратегиями при изменении их эффективности.