

Отчет по разработке итоговой рекомендательной системы для платформы Steam

Выполнил: Шитоев Данил

11 апреля 2026 г.

Содержание

1 Введение и Постановка задачи	2
2 Описание структуры и анализ данных	2
2.1 Структура данных	2
2.2 Предобработка	2
3 Подход к реализации	2
3.1 Этап 1: Retrieval (Content-Based)	3
3.2 Этап 2: Ranking (Hybrid KNN + CB Blend)	3
4 Демонстрация на конкретных примерах	3
5 Гиперпараметры модели и влияние их изменения	3
5.1 Результаты экспериментов	4
5.2 Интерпретация влияния гиперпараметров	4
6 Сравнение с предыдущими моделями	4
7 Выводы	5

1 Введение и Постановка задачи

Целью данной работы является разработка и оценка качества итоговой гибридной рекомендательной системы, объединяющей сильные стороны контентного подхода (Content-Based) и коллаборативной фильтрации (Hybrid KNN).

В предыдущих этапах было выявлено, что отдельные модели имеют свои ограничения:

- **Hybrid KNN** показывает хорошие результаты на активных пользователях, но страдает от разреженности данных.
- **Content-Based** устойчив к холодному старту, но ограничен семантикой текстов.
- **SVD** показал наименьшую эффективность на данном датасете из-за переобучения.

Ключевые задачи финального этапа:

1. Реализовать каскадную архитектуру: Content-Based для отбора кандидатов (Retrieval) и Hybrid KNN для их ранжирования (Ranking) с добавлением весов контентной части.
2. Провести эксперименты по подбору оптимальных гиперпараметров: веса контентной составляющей (`cb_weight`) и размера пула кандидатов (`pool_size`).
3. Оценить качество с использованием метрик HitRate, Precision, Recall, NDCG, RMSE и MAE.
4. Сравнить результаты с предыдущими моделями и доказать превосходство гибридного подхода.

2 Описание структуры и анализ данных

Для обучения итоговой модели использовался расширенный датасет `steam_reco_with_description`.

2.1 Структура данных

Ключевые поля:

- `game_name` и `game_description`: Используются для построения контентного профиля.
- `user_id`, `game_id`, `y_recommended`: Бинарные оценки взаимодействий.

2.2 Предобработка

- Текст очищен от пунктуации и приведен к нижнему регистру.
- Название игры повторялось три раза в документе для усиления его веса при TF-IDF векторизации.
- Использована стратегия разбиения Leave-One-Out для максимизации тестовой выборки.

3 Подход к реализации

Реализована архитектура **Cascade Hybrid with Blended Ranking**.

3.1 Этап 1: Retrieval (Content-Based)

Модель `ContentBasedRetriever` отбирает топ- N кандидатов (пул кандидатов) на основе косинусного сходства векторов TF-IDF профиля пользователя и игр. Это гарантирует тематическую релевантность.

3.2 Этап 2: Ranking (Hybrid KNN + CB Blend)

Модель `HybridKNNRanker` пересортировывает кандидатов, используя:

- **User-Based и Item-Based скоры:** Статистические паттерны взаимодействий.
- **Content-Based скоры:** Семантическое сходство, полученное на первом этапе.
- **Формула смешивания:**

$$Score_{final} = (1 - w_{cb}) \cdot Score_{KNN} + w_{cb} \cdot Score_{CB} + Bonus_{pop} \quad (1)$$

где w_{cb} — гиперпараметр веса контентной части, а $Bonus_{pop}$ — небольшой буст за популярность игры.

4 Демонстрация на конкретных примерах

Для пользователя `12536475869trhgsdf`, имеющего в истории игры *Team Fortress 2* и *Spiral Knights* (жанры: Shooter, Action, Free-to-Play), система сформировала следующие рекомендации:

Таблица 1: Пример рекомендаций для пользователя `12536475869trhgsdf`

Rank	Game Name	Score
1	Unturned	0.596
2	Pirates, Vikings, and Knights II	0.588
3	PlanetSide 2	0.587
4	The Expendabros	0.580
5	Paladins®	0.580

Все рекомендованные игры относятся к жанрам бесплатных многопользовательских шутеров или экшенов, что полностью соответствует профилю пользователя. Высокие скоры обусловлены как статистической похожестью (KNN), так и семантическим сходством описаний (CB).

5 Гиперпараметры модели и влияние их изменения

Были протестированы следующие гиперпараметры:

- `cb_weight` (w_{cb}): 0.2, 0.4, 0.6.
- `pool_size`: 50, 100, 150.

Таблица 2: Сводная таблица результатов подбора гиперпараметров

CB Weight	Pool Size	HitRate@10	Precision@10	Recall@10	NDCG@10	RMSE
0.2	50	0.3104	0.0310	0.3104	0.2313	0.4118
0.2	100	0.3752	0.0375	0.3752	0.2703	0.4091
0.2	150	0.3891	0.0389	0.3891	0.2758	0.4075
0.4	50	0.3071	0.0307	0.3071	0.2212	0.5458
0.4	100	0.3680	0.0368	0.3680	0.2539	0.5400
0.4	150	0.3786	0.0379	0.3786	0.2588	0.5363
0.6	50	0.2991	0.0299	0.2991	0.2111	0.6794
0.6	100	0.3554	0.0355	0.3554	0.2401	0.6703
0.6	150	0.3653	0.0365	0.3653	0.2445	0.6646

5.1 Результаты экспериментов

5.2 Интерпретация влияния гиперпараметров

1. Вес Content-Based (cb_weight):

- Наилучшие результаты достигнуты при $w_{cb} = 0.2$. Это означает, что на этапе ранжирования статистические методы (KNN) должны доминировать (вес 0.8), а контентная часть служить лишь корректирующим фактором.
- Увеличение веса СВ до 0.4 и 0.6 приводит к росту ошибки предсказания (RMSE) и падению метрик ранжирования. Это связано с тем, что чистое текстовое сходство менее точно предсказывает конкретный лайк пользователя, чем поведение похожих игроков.

2. Размер пула кандидатов (pool_size):

- Увеличение пула с 50 до 150 кандидатов монотонно улучшает все метрики (HitRate растёт с 0.31 до 0.39 при $w_{cb} = 0.2$).
- Большой пул позволяет KNN-ранкеру выбрать лучшие игры из более широкого спектра тематически подходящих вариантов, снижая риск отсека реелевантной игры на первом этапе.

Лучшая конфигурация: cb_weight=0.2, pool_size=150.

6 Сравнение с предыдущими моделями

Таблица 3: Финальное сравнение всех реализованных моделей

Модель	HitRate@10	Precision@10	NDCG@10	RMSE	MAE
SVD (FunkSVD)	0.0695	0.0069	0.0297	0.3258	0.2019
Content-Based	0.1046	0.0105	0.0531	-	-
Hybrid KNN	0.1781	0.0178	0.0948	0.3015	0.1637
Cascade Hybrid	0.3891	0.0389	0.2758	0.4075	0.4069

Анализ результатов:

- **Качественный скачок:** Итоговая гибридная модель превзошла лучшую предыдущую модель (Hybrid KNN) более чем в **2 раза** по всем метрикам ранжирования (HitRate: 0.1781 $\rightarrow$ 0.3891).
- **Эффективность каскада:** Использование Content-Based для расширения круга кандидатов (Retrieval) позволило KNN работать с более релевантным подмножеством игр, что значительно повысило точность попаданий.
- **Точность предсказания:** RMSE итоговой модели (0.4075) выше, чем у чистого KNN (0.3015). Это ожидаемо, так как добавление контентной компоненты и нормализация скоров вносят дополнительный шум в абсолютные значения предсказаний, однако для задачи ранжирования (Top-N recommendations) метрики HitRate и NDCG являются более важными, и по ним наблюдается значительный рост.

7 Выводы

1. Превосходство гибридного подхода: Каскадная архитектура с блендингом скоров продемонстрировала наилучшие результаты среди всех реализованных методов.

2. Оптимальный баланс: Наилучшее качество достигается при доминировании коллаборативной фильтрации на этапе ранжирования ($w_{cb} = 0.2$) и использовании широкого пула кандидатов ($N = 150$).

3. Решение проблемы разреженности: Комбинирование семантического поиска (CB) и статистического анализа (KNN) позволило эффективно компенсировать недостатки каждого метода в отдельности, особенно в условиях недостатка данных о взаимодействиях.

4. Перспективы: Дальнейшее улучшение возможно за счет использования более сложных векторных представлений текста (например, Word2Vec или BERT) вместо TF-IDF, что позволит лучше улавливать смысловые нюансы описаний игр.