

Комплексная оффлайн-оценка каскадной гибридной рекомендательной системы: баланс точности, разнообразия и новизны

Выполнил: Шитоев Данил

16 июня 2026 г.

Содержание

1	Введение и постановка задачи	2
2	Архитектура рекомендательной системы	2
2.1	Этап 1: Retrieval (Content-Based)	2
2.2	Этап 2: Ranking (Hybrid KNN + CB Blend)	2
3	Методология расширенной оценки	2
4	Экспериментальный протокол	3
5	Результаты и анализ	3
5.1	Интерпретация результатов	3
6	Выводы и перспективы	4

1 Введение и постановка задачи

Традиционные метрики оценки рекомендательных систем (Precision, Recall, RMSE) измеряют исключительно способность модели предсказывать релевантные элементы. Однако в промышленных сценариях оптимизация только под точность приводит к формированию «пузыря фильтров», снижению удовлетворенности пользователей в долгосрочной перспективе и игнорированию нишевого контента (long-tail problem).

Цель работы: Разработать и валидировать каскадную гибридную модель, обеспечивающую баланс между точностью предсказания и качественными характеристиками выдачи. Для оценки реализован комплексный оффлайн-фреймворк, рассчитывающий метрики beyond-accuracy и проводящий статистическое сравнение конфигураций.

2 Архитектура рекомендательной системы

Реализована двухэтапная каскадная архитектура, разделяющая задачи поиска и ранжирования:

2.1 Этап 1: Retrieval (Content-Based)

На основе названий и описаний игр строится TF-IDF представление. Название дублируется трижды для усиления весов жанровых маркеров. Профиль пользователя U вычисляется как центроид векторов лайкнуемых игр:

$$\vec{U} = \frac{1}{|L_u|} \sum_{i \in L_u} \vec{V}_i \quad (1)$$

Отбирается пул кандидатов $\mathcal{C}$ размера $N \in \{50, 100, 150\}$ с максимальным косинусным сходством $\cos(\vec{U}, \vec{V}_j)$. Это снижает вычислительную сложность второго этапа и гарантирует тематическую релевантность.

2.2 Этап 2: Ranking (Hybrid KNN + CB Blend)

Кандидаты ранжируются гибридной коллаборативной моделью, объединяющей User-Based и Item-Based подходы с коэффициентом $\alpha = 0.3$. Итоговый скор формируется путем смешивания нормализованных статистических и контентных скоров:

$$S_{final} = (1 - w_{cb}) \cdot \hat{S}_{KNN} + w_{cb} \cdot \hat{S}_{CB} + \lambda \cdot P_{norm} \quad (2)$$

где w_{cb} — гиперпараметр веса контента, $\lambda = 0.05$ — коэффициент популяционного буста, P_{norm} — нормализованная популярность игры.

3 Методология расширенной оценки

Класс `OfflineEvaluator` рассчитывает следующие метрики на пользовательском уровне с последующим усреднением:

- **Accuracy:** HitRate@K, Precision@K, Recall@K, NDCG@K.
- **Rating Error:** RMSE, MAE (сравнение предсказанного сора с бинарной целью $r = 1$).

- **Diversity:** Среднее попарное косинусное расстояние между векторами рекомендованных игр:

$$Div(L_u) = 1 - \frac{2}{K(K-1)} \sum_{i < j} \cos(\vec{V}_i, \vec{V}_j) \quad (3)$$

- **Novelty:** Средняя self-information элементов списка:

$$Nov(L_u) = -\frac{1}{K} \sum_{i \in L_u} \log_2 p(i), \quad p(i) = \frac{count(i)}{\sum_j count(j)} \quad (4)$$

- **Coverage:** Доля уникальных игр, рекомендованных хотя бы одному пользователю, относительно общего каталога.

Для проверки статистической значимости различий между конфигурациями применяется попарный t-критерий Стьюдента (Paired t-test).

4 Экспериментальный протокол

1. **Данные:** Датасет `steam_reco_with_descriptions.csv` (3951 пользователь, 351 игра). Отфильтрованы только положительные взаимодействия.
2. **Разбиение:** Leave-One-Out. Для каждого пользователя одна случайная игра помещается в тест, остальные формируют историю.
3. **Гиперпараметры:** Проведен Grid Search по $w_{cb} \in \{0.2, 0.4, 0.6\}$ и $N_{pool} \in \{50, 100, 150\}$.
4. **Процедура:** Для каждой конфигурации запускается полный цикл рекомендаций, агрегируются метрики, выбирается оптимальная комбинация по максимуму HitRate@10.

5 Результаты и анализ

Итоговые метрики лучшей конфигурации ($w_{cb} = 0.2, N_{pool} = 150$) представлены в таблице 1.

Таблица 1: Метрики лучшей конфигурации каскадной гибридной системы

HitRate@10	Precision@10	NDCG@10	Diversity	Novelty	Coverage	RMSE
0.3891	0.0389	0.2758	0.9337	7.3168	0.7749	0.4075

5.1 Интерпретация результатов

- **Точность:** HitRate@10 = 0.3891 означает, что для 39% пользователей система успешно предсказала следующий лайк. NDCG = 0.2758 указывает на корректное ранжирование релевантных игр в верхнюю часть списка.
- **Разнообразие и Новизна:** Значения Diversity = 0.9337 и Novelty = 7.3168 существенно превышают baseline-показатели простых моделей. Система активно рекомендует игры из разных жанров и сеттингов, избегая заикливания на одном поджанре. Высокая новизна свидетельствует о поддержке long-tail контента.

- **Покрытие:** Coverage = 77.5% подтверждает, что более трех четвертей каталога участвует в выдаче. Это критически важно для монетизации и удержания авторов нишевых проектов.
- **Влияние гиперпараметров:** Снижение w_{cb} до 0.2 показало, что на этапе Ranking статистика KNN является более надежным сигналом, чем текст. Увеличение пула до 150 снизило риск ложного отсека релевантных кандидатов на этапе Retrieval.

6 Выводы и перспективы

1. **Эффективность каскада:** Последовательное применение Content-Based и Hybrid KNN позволило совместить тематический охват и персонализированное ранжирование, превзойдя результаты изолированных моделей.